

Planejamento do Estudo Exploratório:

Ansiedade Social e Fatores de Estilo de Vida

Integrantes:

Ana Paula Bernardo dos Santos, Nº USP 14785580

Artur Daichi Gonçalves Inazaki, Nº USP 14676716

Rafael de Sousa Muniz, Nº USP 14659644

Sara Leticia Santos Silva, Nº USP 14677190

Disciplina: ACH2177 - Introdução à Ciência de Dados

Professor: Norton T. Roman

1. Passo 1: Formule uma questão de pesquisa geral

O objetivo principal desta pesquisa é investigar como variáveis de comportamento, estilo de vida e indicadores físicos se relacionam com a intensidade da ansiedade social em diferentes perfis de indivíduos.

Questão de pesquisa: "De que maneira a interação entre o **perfil demográfico**, os **hábitos de vida**, os **indicadores biométricos** e o **histórico clínico** influencia a intensidade da ansiedade social e quais desses pilares possuem maior peso para a sua predição?".

2. Passo 2: População e coleta de dados

2.1 Caracterização da Base e População

Nossa população-alvo é composta por indivíduos que apresentam variados níveis de ansiedade social, abrangendo diferentes ocupações e faixas etárias.

- **Fonte dos Dados:** O conjunto de dados foi obtido via Kaggle (Social Anxiety Dataset). Essa base foi escolhida por conter diversas informações sociais

que podem ou não influenciar no nível de ansiedade social, e também por conter uma boa quantidade de dados, totalizando 11000 registros.

- **Amostragem:** A coleta original baseou-se em respostas de questionários e estudos observacionais, caracterizando uma amostragem por conveniência.
- **Limitações:** Por ser baseada em relatos voluntários e potencialmente em um ambiente digital, a amostra pode conter vieses de participação e autodeclaração imprecisa.

2.2 Caracterização das Variáveis e Fatores

Nesta etapa, detalhamos as variáveis contidas no arquivo **enhanced_anxiety_dataset.csv** (o link está anexado). A classificação segue a natureza dos dados (Qualitativos ou Quantitativos) e seu nível de mensuração (Nominal, Ordinal, Intervalar ou Razão).

Tabela de Caracterização das Variáveis

Variável	Tipo de Variável	Nível de Medida	Descrição/Justificativa
Age	Quantitativa	Razão (Discreta)	Idade em anos. Possui zero absoluto.
Gender	Qualitativa	Nominal	Categorias de gênero (Male, Female, Other) sem ordem intrínseca.
Occupation	Qualitativa	Nominal	Profissão do indivíduo. Categórica sem hierarquia.
Sleep Hours	Quantitativa	Razão (Contínua)	Horas de sono. Permite valores decimais e possui zero absoluto.
Physical Activity	Quantitativa	Razão (Contínua)	Horas de atividade física semanal. Possui zero absoluto.

Caffeine Intake	Quantitativa	Razão (Discreta)	Miligramas de café por dia. Possui zero absoluto.
Alcohol Consumption	Quantitativa	Razão (Discreta)	Doses por semana. Possui zero absoluto.
Smoking	Qualitativa	Nominal	Status de fumante (Yes/No).
Family History	Qualitativa	Nominal	Histórico familiar de ansiedade (Yes/No).
Stress Level	Qualitativa	Ordinal	Escala de 1 a 10. Embora numérica, representa níveis de intensidade com ordem.
Heart Rate (bpm)	Quantitativa	Razão (Discreta)	Batimentos por minuto. Medida física direta. Possui zero absoluto.
Breathing Rate	Quantitativa	Razão (Discreta)	Respiração por minuto. Medida física direta. Possui zero absoluto.
Sweating Level	Qualitativa	Ordinal	Escala de 1 a 5 para nível de sudorese.
Dizziness	Qualitativa	Nominal	Presença de tontura (Yes/No).
Medication	Qualitativa	Nominal	Uso de medicação para ansiedade (Yes/No).

Therapy Sessions	Quantitativa	Razão (Discreta)	Quantidade mensal de sessões de terapia. Possui zero absoluto.
Recent Major Life Event	Qualitativa	Nominal	Ocorrência de evento impactante recente (Yes/No).
Diet Quality	Qualitativa	Ordinal	Escala de 1 a 10 para qualidade da alimentação.
Anxiety Level	Quantitativa	Razão (Contínua)	Variável Alvo (1-10). Tratada como contínua para modelos de regressão.

OBS: Nível de Medida da Anxiety Level - Originalmente Qualitativa Ordinal, mas será tratada como Quantitativa neste estudo para permitir o uso de algoritmos de regressão e o cálculo de métricas de tendência central (como a média), facilitando a identificação de padrões de intensidade

Definição dos Fatores de Análise

Para responder à questão de pesquisa, agruparemos as variáveis acima nos seguintes **fatores**, que serão os pilares da nossa análise exploratória:

1. **Fator Demográfico e Ocupacional:** Composto por **Age, Gender e Occupation**.
 - *Objetivo:* Entender se certos perfis profissionais ou faixas etárias são mais vulneráveis à ansiedade social.
2. **Fator de Estilo de Vida:** Composto por **Sleep Hours, Physical Activity, Diet Quality, Caffeine Intake, Alcohol e Smoking**.
 - *Objetivo:* Identificar se hábitos saudáveis (ou nocivos) possuem correlação direta com a pontuação de ansiedade.
3. **Fator Biométrico e de Saúde:** Composto por **Heart Rate, Breathing Rate, Sweating Level, Dizziness e Stress Level**.
 - *Objetivo:* Verificar se os sintomas físicos "denunciam" o nível de ansiedade, servindo como possíveis preditores automáticos.
4. **Fator Clínico/Histórico:** Composto por **Family History, Medication, Recent Major Life Event e Therapy Sessions**.
 - *Objetivo:* Observar o impacto do suporte terapêutico, da genética e de eventos recentes na intensidade do transtorno.

Limitações da Relação Variável-Fator

Uma limitação importante é que variáveis como **Stress Level** e **Diet Quality** são baseadas em **autopercepção** (subjetivas), o que pode introduzir ruído nos dados em comparação com medidas objetivas como **Heart Rate** (batimentos cardíacos), e é importante notar que variáveis binárias como **Dizziness** ou **Recent Major Life Event** simplificam fenômenos complexos em apenas "Sim" ou "Não". Isso pode limitar a sensibilidade do modelo, pois não captura a *intensidade* da tontura ou o *tipo* de evento de vida. Além disso, a escala de 1 a 10 para **Anxiety Level** pode ser interpretada de formas diferentes por cada participante.

3. Passo 3: Explore os dados e visualize

A exploração ocorrerá exclusivamente na subamostra de 10% (1100 registros). Planejamos as seguintes ações:

- **Curadoria:** Verificação de valores nulos (NaN) e normalização de variáveis de texto (como ocupações).
- **Visualizações:**
 - **Histogramas:** Para observar a distribuição das idades e dos níveis de ansiedade (1-10).
 - **Boxplots:** Para comparar o nível de ansiedade entre diferentes ocupações e gêneros.
 - **Heatmap de Correlação:** Para identificar quais fatores físicos (como Stress level) têm maior relação estatística com a variável alvo.

4. Modelagem e Avaliação (Planejamento Futuro)

4.1 Modelagem

Pretendemos aplicar modelos de Aprendizado de Máquina Supervisionado voltados para **Regressão**, uma vez que o objetivo é prever a intensidade exata do nível de ansiedade (escala de 1 a 10). Os modelos candidatos são:

- **Regressão Linear:** Como modelo de base (*baseline*) para identificar relações lineares simples entre os hábitos de vida e a ansiedade.
- **Random Forest Regressor:** Para capturar interações complexas e não-lineares entre os pilares biométricos, demográficos e históricos, além de permitir a análise de importância das variáveis (*feature importance*).

A escolha pela regressão justifica-se pela natureza da variável alvo, que embora originalmente ordinal, será tratada como quantitativa para permitir uma análise mais refinada dos pesos de cada fator preditor.

4.2 Avaliação

- **Divisão de Dados:** O conjunto será dividido em Treino (80%) e Teste (20%, intocado).
- **Métricas:** Utilizaremos o Erro Médio Absoluto (MAE) ou o Erro Quadrático Médio (MSE) para avaliar a precisão das previsões numéricas.

4.3 Comunicação dos Resultados

O público-alvo desta pesquisa abrange:

- Profissionais de Saúde e Bem-Estar: Psicólogos ou gestores de RH interessados em identificar gatilhos de ansiedade relacionados ao estilo de vida e ocupação.

A divulgação será realizada da seguinte forma:

- Relatório Técnico (Alta Profundidade): Será elaborado um documento detalhando todas as etapas do processo, desde a limpeza dos dados até as métricas de erro (MAE ou MSE) dos modelos.
- Apresentação de Descobertas (Média Profundidade): Os principais achados (ex: "Qual o fator com maior peso na predição da ansiedade?") serão sintetizados em um formato visual (infográfico ou dashboard no Power BI), focando na interpretação prática das correlações para um público menos técnico.
- Repositório Digital: O código-fonte e o planejamento serão disponibilizados em plataforma de versionamento (GitHub), permitindo que outros estudantes consultem a metodologia aplicada no estudo.

5. Passo 4: Refine a(s) questão(ões) de pesquisa

Após a exploração, buscaremos responder questões mais específicas, como:

- "Existe um limite de horas de sono abaixo do qual o nível de ansiedade sobe drasticamente?"
- "O consumo de cafeína tem maior impacto na ansiedade do que a falta de atividade física?"
- "É possível prever o nível de ansiedade apenas com indicadores físicos como batimentos e respiração?"

6. Cronograma de Desenvolvimento

Abaixo, o cronograma para cumprimento dos prazos da disciplina:

Semana	Atividade Detalhada

Semana 1	Curadoria Inicial: Revisão da base de dados e tratamento de valores ausentes (NaN).
Semana 2	Codificação de Dados: Transformação de variáveis nominais (Gênero, Ocupação) em numéricas via <i>One-Hot Encoding</i> .
Semana 3	Exploração Descritiva: Cálculo de médias, medianas e desvios padrão na subamostra de 10%.
Semana 4	Visualização de Dados: Criação de histogramas e boxplots para identificar padrões visuais iniciais.
Semana 5	Análise de Correlação: Geração de mapas de calor para verificar a força da relação entre hábitos e ansiedade.
Semana 6	Engenharia de Variáveis: Normalização das escalas e criação de novos fatores a partir das medições biométricas.
Semana 7	Modelagem Inicial: Divisão dos dados em treino e teste (reservando a porção intocada) e treinamento do primeiro modelo.
Semana 8	Ajuste de Hiperparâmetros: Refinamento dos modelos de Machine Learning para reduzir o erro (MAE).
Semana 9	Avaliação Final: Aplicação do modelo final nos dados de teste intocados e verificação da performance.
Semana 10	Interpretação de Resultados: Análise de quais fatores (estilo de vida vs. histórico) tiveram mais peso na predição.

Semana 11	Comunicação e Submissão: Finalização do relatório PDF com gráficos finais e entrega final.
-----------	---