

Análise Exploratória :
Ansiedade Social e Fatores de Estilo de Vida

Integrantes:

Ana Paula Bernardo dos Santos, Nº USP 14785580

Artur Daichi Gonçalves Inazaki, Nº USP 14676716

Rafael de Sousa Muniz, Nº USP 14659644

Sara Leticia Santos Silva, Nº USP 14677190

Disciplina: ACH2177 - Introdução à Ciência de Dados

Professor: Norton T. Roman

1. Formulação da questão de pesquisa geral

O objetivo principal desta pesquisa é investigar como variáveis de comportamento, estilo de vida e indicadores físicos se relacionam com a intensidade da ansiedade social em diferentes perfis de indivíduos.

Questão de pesquisa: "De que maneira a interação entre o **perfil demográfico**, os **hábitos de vida**, os **indicadores biométricos** e o **histórico clínico** influencia a intensidade da ansiedade social e quais desses pilares possuem maior peso para a sua predição?".

2. População e coleta de dados

2.1 Caracterização da Base e População

A população-alvo compreende indivíduos com diversos níveis de ansiedade social, abrangendo uma ampla gama de ocupações e faixas etárias para garantir a heterogeneidade dos dados.

- **Fonte dos Dados:** O conjunto de dados foi obtido via Kaggle (Social Anxiety Dataset). Essa base foi escolhida por conter diversas informações sociais que podem ou não influenciar no nível de ansiedade social, e também por conter uma boa quantidade de dados, totalizando 11000 registros.
- **Amostragem:** A coleta original baseou-se em respostas de questionários e estudos observacionais, caracterizando uma amostragem por conveniência.
- **Limitações:** Por ser baseada em relatos voluntários e potencialmente em um ambiente digital, a amostra pode conter vieses de participação e autodeclaração imprecisa.

2.2 Caracterização das Variáveis e Fatores

Nesta etapa, detalhamos as variáveis contidas no arquivo **enhanced_anxiety_dataset.csv** (o link está anexado). A classificação segue a natureza dos dados (Qualitativos ou Quantitativos) e seu nível de mensuração (Nominal, Ordinal, Intervalar ou Razão).

Tabela de Caracterização das Variáveis

Variável	Tipo de Variável	Nível de Medida	Descrição/Justificativa
Age	Quantitativa	Razão (Discreta)	Idade em anos. Possui zero absoluto.

Gender	Qualitativa	Nominal	Categorias de gênero (Male, Female, Other) sem ordem intrínseca.
Occupation	Qualitativa	Nominal	Profissão do indivíduo. Categórica sem hierarquia.
Sleep Hours	Quantitativa	Razão (Contínua)	Horas de sono. Permite valores decimais e possui zero absoluto.
Physical Activity	Quantitativa	Razão (Contínua)	Horas de atividade física semanal. Possui zero absoluto.
Caffeine Intake	Quantitativa	Razão (Discreta)	Miligramas de café por dia. Possui zero absoluto.
Alcohol Consumption	Quantitativa	Razão (Discreta)	Doses por semana. Possui zero absoluto.
Smoking	Qualitativa	Nominal	Status de fumante (Yes/No).
Family History	Qualitativa	Nominal	Histórico familiar de ansiedade (Yes/No).
Stress Level	Qualitativa	Ordinal	Escala de 1 a 10. Embora numérica, representa níveis de intensidade com ordem.
Heart Rate (bpm)	Quantitativa	Razão (Discreta)	Batimentos por minuto. Medida física direta. Possui zero absoluto.
Breathing Rate	Quantitativa	Razão (Discreta)	Respiração por minuto. Medida física direta. Possui zero absoluto.
Sweating Level	Qualitativa	Ordinal	Escala de 1 a 5 para nível de sudorese.
Dizziness	Qualitativa	Nominal	Presença de tontura (Yes/No).

Medication	Qualitativa	Nominal	Uso de medicação para ansiedade (Yes/No).
Therapy Sessions	Quantitativa	Razão (Discreta)	Quantidade mensal de sessões de terapia. Possui zero absoluto.
Recent Major Life Event	Qualitativa	Nominal	Ocorrência de evento impactante recente (Yes/No).
Diet Quality	Qualitativa	Ordinal	Escala de 1 a 10 para qualidade da alimentação.
Anxiety Level	Quantitativa	Razão (Contínua)	Variável Alvo (1-10). Tratada como contínua para modelos de regressão.

OBS: Nível de Medida da Anxiety Level - Originalmente Qualitativa Ordinal, mas será tratada como Quantitativa neste estudo para permitir o uso de algoritmos de regressão e o cálculo de métricas de tendência central (como a média), facilitando a identificação de padrões de intensidade

Definição dos Fatores de Análise

Para responder à questão de pesquisa, agruparemos as variáveis acima nos seguintes **fatores**, que serão os pilares da nossa análise exploratória:

1. **Fator Demográfico e Ocupacional:** Composto por **Age, Gender e Occupation**.
 - *Objetivo:* Entender se certos perfis profissionais ou faixas etárias são mais vulneráveis à ansiedade social.
2. **Fator de Estilo de Vida:** Composto por **Sleep Hours, Physical Activity, Diet Quality, Caffeine Intake, Alcohol e Smoking**.
 - *Objetivo:* Identificar se hábitos saudáveis (ou nocivos) possuem correlação direta com a pontuação de ansiedade.
3. **Fator Biométrico e de Saúde:** Composto por **Heart Rate, Breathing Rate, Sweating Level, Dizziness e Stress Level**.
 - *Objetivo:* Verificar se os sintomas físicos "denunciam" o nível de ansiedade, servindo como possíveis preditores automáticos.
4. **Fator Clínico/Histórico:** Composto por **Family History, Medication, Recent Major Life Event e Therapy Sessions**.
 - *Objetivo:* Observar o impacto do suporte terapêutico, da genética e de eventos recentes na intensidade do transtorno.

Limitações da Relação Variável-Fator

Uma limitação importante é que variáveis como **Stress Level** e **Diet Quality** são baseadas em **autopercepção** (subjetivas), o que pode introduzir ruído nos dados em comparação com medidas objetivas como **Heart Rate** (batimentos cardíacos), e é importante notar que variáveis binárias como **Dizziness** ou **Recent Major Life Event** simplificam fenômenos complexos em apenas "Sim" ou "Não". Isso pode limitar a sensibilidade do modelo, pois não captura a *intensidade* da tontura ou o *tipo* de evento de vida. Além disso, a escala de 1 a 10 para **Anxiety Level** pode ser interpretada de formas diferentes por cada participante.

3. Exploração dos dados e visualização

3.1 Curadoria, Avaliação de Viés e Amostragem


A exploração dos dados concentrou-se em uma subamostra de 10% (1.100 registros), preservando a integridade do conjunto destinado a testes futuros. A análise de consistência confirmou a ausência de dados faltantes ou valores nulos, assegurando a robustez estatística do recorte.







Avaliação de Viés: Como não foi necessária a exclusão de registros por ausência de dados, o estudo está completamente livre de vieses de seleção decorrentes de perda de informação. A integridade das proporções demográficas, de estilo de vida, clínicas e biométricas originais foi integralmente preservada.







Destino da Subamostra: A subamostra curada será reintegrada ao conjunto de dados total novamente. O total de registros será submetido à divisão para *Machine Learning*, em que 80% da base passará por validação cruzada (Treino) e os 20% restantes ficarão isolados (Teste).







3.2 Análise de Representatividade da Subamostra







Para atestar visualmente a validade da nossa amostragem, os gráficos abaixo comparam a distribuição de todas as variáveis entre a base original completa (em azul) e a subamostra extraída (em laranja):



























Ao analisar as distribuições qualitativas e quantitativas de todas as 19 variáveis, conclui-se que a subamostra de 10% espelha com absoluta fidelidade estatística a base original, validando-a como uma miniatura representativa e garantindo a solidez das premissas para as próximas etapas do estudo.

3.3 Tabela de valores de tendência central

Com a representatividade garantida, avançamos, conseqüentemente, para o cálculo das medidas de tendência central da subamostra, detalhadas na tabela a seguir:

Variável	Média	Mediana	Moda
Age	40.09	39.0	35
Gender	N/A	N/A	Female
Occupation	N/A	N/A	Student
Sleep Hours	6.61	6.7	6.7
Physical Activity (hrs/week)	2.98	2.8	1.4
Caffeine Intake (mg/day)	284.18	272.0	289



Alcohol Consumption (drinks/week)	9.3	9.0	15
Smoking	N/A	N/A	Yes
Family History of Anxiety	N/A	N/A	Yes
Stress Level (1-10)	N/A	6	10
Heart Rate (bpm)	90.39	91.0	112
Breathing Rate (breaths/min)	20.87	21.0	22
Sweating Level (1-5)	N/A	3	4
Dizziness	N/A	N/A	No
Medication	N/A	N/A	Yes
Therapy Sessions (per month)	2.55	2.0	1









Recent Major Life Event	N/A	N/A	Yes
Diet Quality (1-10)	N/A	5	4
Anxiety Level (1-10)	4.03	4.0	3.0









A análise revela o perfil base da nossa amostra: um indivíduo médio com cerca de 40 anos, que dorme 6,6 horas/noite e consome 284 mg de cafeína. Metodologicamente, suprimimos a média e a mediana das variáveis qualitativas e ordinais (como Gênero e Nível de Estresse) por inadequação matemática, utilizando apenas a Moda, que evidenciou a predominância de mulheres e estudantes. Por fim, nossa variável alvo (*Anxiety Level*) registrou média e mediana em torno de 4.0, indicando uma concentração de casos de ansiedade de intensidade leve a moderada.

3.4 Relação e Dispersão com a Variável Alvo

Para investigar o impacto de cada fator sobre a nossa variável alvo (*Anxiety Level*), construímos painéis de *Boxplots*. O objetivo desta etapa visual é identificar se alguma variável dita, de forma isolada, a gravidade do transtorno:







Fator Demográfico e Ocupacional (Age, Gender, Occupation): Ao aprofundar a análise deste pilar, notam-se comportamentos distintos entre as variáveis. O **Gênero (Gender)** apresentou uma uniformidade estatística absoluta: as medianas e as caixas de dispersão (IQR) alinham-se perfeitamente entre todas as categorias, indicando que a identificação de gênero, isoladamente, não determina a severidade do transtorno. Na **Idade (Age)**, embora a distribuição seja estável nos níveis leves e moderados (com medianas orbitando os 40 anos), observa-se uma sutil inclinação de queda nos níveis mais críticos de ansiedade (8 a 10), onde a mediana cai para a faixa dos 35 anos, sugerindo que adultos ligeiramente mais jovens tendem a relatar picos mais severos. Contudo, o grande destaque analítico do grupo é a **Ocupação (Occupation)**. Ela demonstrou a maior variedade morfológica de dispersão: categorias como Cientistas (*Scientist*) e Advogados (*Lawyer*) apresentam caixas e quartis superiores mais elevados, enquanto Professores (*Teacher*) e *Freelancers* concentram-se em patamares visuais mais brandos. Isso atesta que a pressão do contexto profissional e acadêmico introduz nuances importantes e variáveis para o transtorno, ainda que não o defina de forma solitária.

Fator de Estilo de Vida (Sleep Hours, Physical Activity, Diet Quality, Caffeine Intake, Alcohol, Smoking): Ao examinarmos detalhadamente as variáveis de rotina, notamos que elas não são estáticas, com exceção do **Smoking** que se manteve igual, e reagem de forma contundente à progressão do transtorno. Embora não formem uma "escadinha" linear perfeita desde o início, as caixas de dispersão revelam comportamentos críticos nos níveis mais severos de ansiedade (8 a 10): as medianas de **Qualidade da Dieta** e de **Atividade Física** sofrem uma retração, indicando uma tendência à negligência de rotinas saudáveis. Simultaneamente, os valores de ingestão de **Cafeína** e de **Consumo de Álcool** aumentam, sinalizando um provável aumento no abuso de estimulantes e bebidas como mecanismo de escape. O destaque mais alarmante deste pilar, contudo, vai para as **Horas de Sono**, que sofrem uma queda brusca e visível em suas medianas e limites superiores nos graus mais agudos de ansiedade, confirmando a privação de sono como um forte sintoma associado às crises severas. Essas flutuações comprovam que o estilo de vida do paciente interage ativamente com a gravidade do transtorno.



Fator Biométrico e de Saúde (Heart Rate, Breathing Rate, Sweating Level, Dizziness, Stress Level): Quando avaliamos as reações do corpo humano, a correlação visual com o transtorno torna-se ainda mais nítida e direta. O grande protagonista deste pilar é o **Nível de Stress (Stress Level)**, que exibe uma progressão quase linear: à medida que a ansiedade atinge os seus graus mais severos (8 a 10), as caixas de dispersão e as medianas sofrem um claro e expressivo deslocamento para o topo do gráfico. Um comportamento análogo, revelando o corpo no seu limite fisiológico, é observado na **Frequência Cardíaca (Heart Rate)** e na **Taxa de Respiração (Breathing Rate)**, que apresentam um aumento considerável dos seus limites superiores e medianas nos maiores níveis de ansiedade. Em contrapartida, sintomas como a **Tontura (Dizziness)** e o **Nível de**

Sudorese (*Sweating Level*) apresentam caixas mais sobrepostas e distribuídas ao longo de todos os grupos, demonstrando que, embora presentes, atuam de forma mais difusa e não servem como termômetros isolados para cravar o nível exato do transtorno.

Fator Clínico e Histórico (Family History, Medication, Recent Major Life Event, Therapy Sessions): Nas variáveis de histórico clínico, o impacto visual das **Sessões de Terapia (*Therapy Sessions*)** é indiscutível: observa-se um salto drástico nas medianas e na base das caixas quando o paciente atinge os níveis mais agudos de ansiedade (8 a 10), evidenciando que quadros severos estão diretamente atrelados a uma maior necessidade de intervenção clínica. Ao analisar as variáveis dicotômicas (Sim/Não), notamos sutilezas importantes que diferenciam os perfis. Pacientes que possuem **Histórico Familiar (*Family History*)** positivo ou que sofreram um **Evento Recente Impactante (*Recent Major Life Event*)** apresentam um leve deslocamento das medianas para cima (do nível 3 para o 4) em comparação aos que não possuem, sugerindo que esses fatores atuam como agravantes que elevam o "pisso" da intensidade do transtorno. Em contrapartida, o **Uso de Medicação (*Medication*)** apresenta caixas e medianas perfeitamente sobrepostas em ambos os cenários, indicando que essa variável binária responde de forma generalizada na amostra e não distingue, visualmente, a gravidade isolada das crises.

3.5 Análise de Correlação Linear

A etapa final da nossa análise consistiu em aplicar o cálculo de Correlação de Pearson através de Mapas de Calor (*Heatmaps*). Para viabilizar a análise estatística de categorias em formato de texto, aplicamos previamente a técnica de *One-Hot Encoding* nas colunas de Ocupação e Gênero, gerando um mapa de correlação exclusivo para elas:



O heatmap focado na variável alvo (*Anxiety Level*) revelou descobertas cruciais. Diferente da grande maioria das variáveis que apresentaram valores menores a 0.5, uma "tríade" de fatores demonstrou correlações lineares de moderadas a fortes. O **Nível de Estresse (0.650)** e a quantidade de **Sessões de Terapia (0.535)** apresentaram forte correlação positiva, indicando que o agravamento do estresse e a consequente necessidade de intervenção clínica caminham lado a lado com picos de ansiedade. Em contrapartida, as **Horas de Sono (-0.545)** apresentaram uma expressiva correlação negativa, atuando como um poderoso indicador: quanto menos o paciente dorme, maior a gravidade do transtorno. As demais 15 variáveis, no entanto, demonstraram dependência linear muito inferior quando avaliadas isoladamente.

3.6 Conclusão da Análise

A Análise Exploratória cumpriu seu objetivo fundamental de validar a integridade dos dados e mapear o comportamento do transtorno. Ao cruzarmos as evidências visuais dos *boxplots* com a prova matemática dos *heatmaps*, identificamos que, embora a ansiedade social seja um fenômeno estritamente multifatorial, ela apresenta uma "tríade" de correlações lineares relevantes: o **Nível de Estresse (0.650)** e a frequência de **Sessões de Terapia (0.535)** apresentam impactos positivos na severidade do quadro, enquanto as **Horas de Sono (-0.545)** atuam como um fator protetor.

Contudo, a baixa correlação das demais 15 variáveis confirma que a ansiedade não é fruto de uma relação simples de causa e efeito isolada. Essa disparidade entre os fatores reforça a nossa estratégia para a fase de modelagem: a Regressão Linear, embora útil como *baseline*, seria insuficiente para decodificar o problema. Avançamos, portanto, para a etapa de modelagem com a justificativa clara de que precisaremos de algoritmos avançados, como o **Random Forest Regressor**, capazes de integrar o peso linear dessa "tríade" com as complexas interações não-lineares dos demais hábitos de vida, decifrando assim a teia oculta que desencadeia as crises de ansiedade.

4. Modelagem e Avaliação

4.1 Modelagem

A modelagem utilizará algoritmos de Aprendizado Supervisionado para Regressão, visando prever a intensidade da ansiedade (escala 1-10). A complexidade multifatorial identificada nessa fase de análise exploratória justifica o uso de abordagens que capturem relações não-lineares:

- **Regressão Linear Múltipla:** Será utilizada como o nosso modelo de base (*baseline*). Ela nos ajudará a verificar se existem relações lineares simples entre as variáveis de estilo de vida e a ansiedade.
- **Random Forest Regressor:** Será o nosso modelo principal. Como os gráficos mostraram que nenhum fator sozinho dita a ansiedade, este algoritmo de árvore de decisão será essencial para capturar as interações complexas e não-lineares entre os dados biométricos, demográficos e históricos, além de nos permitir analisar a importância real de cada variável (*feature importance*).

Para viabilizar a entrada dos dados nos modelos, faremos duas transformações essenciais: o mapeamento binário (transformar respostas de "Yes"/"No" em 1 e 0) e o *One-Hot Encoding* (para transformar variáveis categóricas como gênero e ocupação em colunas numéricas independentes).

4.2 Avaliação

- **Divisão dos Dados:** Utilizaremos o método *Holdout*, dividindo o conjunto completo de dados em Treino (80%) e Teste (20%, intocado). A subamostra de 10% usada para a análise será reunida ao todo antes dessa divisão. Os 20% de teste ficarão totalmente protegidos para a validação final, evitando qualquer vazamento de dados (*data leakage*).
- **Validação Cruzada:** Aplicaremos a técnica de *K-Fold Cross-Validation* (Validação Cruzada em K partes) exclusivamente sobre os 80% dos dados de treino. Isso garantirá que o modelo seja treinado e testado em múltiplos subgrupos internos, tornando-o muito mais robusto e evitando que ele apenas decore as respostas (*overfitting*).
- **Métricas:** Avaliaremos a precisão das previsões numéricas utilizando o Erro Médio Absoluto (MAE) e o Erro Quadrático Médio (MSE), calculando exatamente quantos pontos o modelo erra, em média, na nossa escala de 1 a 10.

4.3 Comunicação dos Resultados

O público-alvo desta pesquisa abrange profissionais de saúde, psicólogos e gestores de bem-estar interessados em identificar gatilhos de ansiedade relacionados ao estilo de vida e à ocupação. A divulgação será realizada de três formas:

- **Relatório Técnico (Alta Profundidade):** Um documento detalhado com todas as etapas do processo, desde a curadoria dos dados até as métricas de erro dos modelos.
- **Apresentação de Descobertas (Média Profundidade):** Os principais achados serão sintetizados em um formato visual (como um infográfico ou

painel interativo no Power BI), focando na interpretação prática das correlações para um público menos técnico.

- **Repositório Digital:** O código-fonte e o planejamento serão disponibilizados no GitHub, permitindo que outros estudantes e pesquisadores consultem a metodologia aplicada.

5. Refinamento das Questões de Pesquisa

Após a exploração visual e matemática dos dados conseguimos refinar o nosso foco. Em vez de buscar respostas isoladas, buscaremos responder a questões mais específicas e integradas durante a modelagem, tais como:

- *"Existe um limite crítico de horas de sono combinado com altos níveis de estresse que faça o nível de ansiedade social disparar drasticamente?"*
- *"O consumo diário de cafeína e álcool tem um impacto maior na intensidade da ansiedade do que a falta de atividade física semanal?"*
- *"É possível criar um modelo preditivo confiável para o nível de ansiedade combinando apenas indicadores físicos objetivos (como batimentos e respiração) com o histórico clínico do paciente?"*

6. Cronograma de Desenvolvimento

Abaixo, o cronograma para cumprimento dos prazos da disciplina:

Semana	Atividade Detalhada
Semana 1	Curadoria Inicial: Revisão da base de dados e tratamento de valores ausentes (NaN).
Semana 2	Codificação de Dados: Transformação de variáveis nominais (Gênero, Ocupação) em numéricas via <i>One-Hot Encoding</i> .
Semana 3	Exploração Descritiva: Cálculo de médias, medianas e desvios padrão na subamostra de 10%.
Semana 4	Visualização de Dados: Criação de histogramas e boxplots para identificar padrões visuais iniciais.

Semana 5	Análise de Correlação: Geração de mapas de calor para verificar a força da relação entre hábitos e ansiedade.
Semana 6	Engenharia de Variáveis: Normalização das escalas e criação de novos fatores a partir das medições biométricas.
Semana 7	Modelagem Inicial: Divisão dos dados em treino e teste (reservando a porção intocada) e treinamento do primeiro modelo.
Semana 8	Ajuste de Hiperparâmetros: Refinamento dos modelos de Machine Learning para reduzir o erro (MAE).
Semana 9	Avaliação Final: Aplicação do modelo final nos dados de teste intocados e verificação da performance.
Semana 10	Interpretação de Resultados: Análise de quais fatores (estilo de vida vs. histórico) tiveram mais peso na predição.
Semana 11	Comunicação e Submissão: Finalização do relatório PDF com gráficos finais e entrega final.