

ACH2177 - Introdução à Ciência de Dados

Primeiro Exercício Prático

Norton T. Roman

13/03/2026

1 Instruções Gerais

Esse trabalho pode ser feito individualmente ou em grupos de até 5 pessoas. Cada grupo deve planejar um Estudo Exploratório, seguindo os passos vistos em aula (Aula 02). Esse planejamento irá servir como base para análises exploratórias básicas (no segundo trabalho) bem como para aplicação de modelos de Aprendizado de Máquina (terceiro trabalho). É imprescindível que esse planejamento inclua alguma técnica de Aprendizado de Máquina, muito embora qual técnica será usada possa ser deixado em aberto nesse documento.

Seu planejamento deve ser específico o suficiente para que vocês possam segui-lo nas fases posteriores, mas também geral o suficiente para permitir a exploração dos dados, não devendo ser pormenorizado a ponto de impedir você de buscar padrões interessantes e explorar alternativas. Você deve também apresentar um cronograma para a futura execução da exploração e teste de modelo. Atente para o prazo da disciplina: não planeje fazer coisas demais, então inclua um cronograma, indicando semana-a-semana o desenvolvimento desses passos.

2 Planejamento do Estudo Exploratório

Mesmo um estudo exploratório precisa ser planejado. Conforme visto em aula, esse planejamento segue alguns passos gerais. Cada um desses passos será apresentado nas seções que seguem, tomando como exemplo nossa base sobre relatos de avistamentos de OVNI's. Vale lembrar, contudo, que apenas os primeiros passos devem ser executados nesse trabalho (conforme indicado no que segue), sendo os demais incluídos no planejamento futuro.

Além disso, o exemplo mostrado nesse documento não deve ser entendido como algo a ser seguido à risca, mas apenas como uma referência de como seu estudo pode ser planejado, permitindo um grau de detalhamento suficiente para sua reprodução, mas com grande liberdade para exploração. Naturalmente, essa é uma questão subjetiva, e definir o limiar entre detalhamento e liberdade caberá a você.

2.1 Passo 1: Formule uma questão de pesquisa geral

Comece definindo o objetivo principal da pesquisa. Esse pode ser bem amplo. Elenque também os objetivos secundários, se houver.

Exemplo:

O objetivo principal da presente pesquisa é estudar possíveis padrões nos relatos de avistamentos de OVNI's.

Na sequência, defina a questão de pesquisa. Trata-se do que queremos saber, de uma questão geral. Também aqui, se houver questões secundárias, elas devem ser elencadas aqui.

Exemplo:

A questão de pesquisa a ser explorada é: “existem padrões na localização geográfica dos avistamentos?”.

2.2 Passo 2: Defina a população e colete os dados

Aqui deve-se definir a quem (ou a que) a questão de pesquisa se aplica, além de descrever o procedimento que levou à obtenção dos dados. Note que isso implica você já ter obtido uma base para análise. Qual base utilizar fica a seu critério.

Basicamente, você deve:

- Explicitar a população-alvo coberta pela base.
 - Caracterizar a base, descrevendo a técnica de amostragem utilizada para sua coleta.
 - Fazer uma análise crítica sobre se a amostragem utilizada reflete realmente a população. Inclua os resultados dessa análise como limitações à pesquisa.
-

Exemplo:

Nossa população-alvo é formada, idealmente, por todo relato de avistamento de OVNI's existente.

Dadas então essa população-alvo e a questão de pesquisa apresentada, uma busca pela web levou a várias possibilidades. Dentre as opções, o conjunto escolhido foi o disponibilizado em <https://www.kaggle.com/datasets/NUFORC/ufo-sightings>. Esse conjunto foi escolhido por conter a base oficial da NUFORC (National UFO Research Center), acrescentado de informação de latitude e longitude para alguns (poucos) países.

A amostragem, conforme consta do *site* citado, foi feita por conveniência, sendo relatos espontâneos de testemunhas. Como tal, sua cobertura em relação à população certamente não é grande (até por uma barreira linguística, dado que o relato deve ser feito em inglês), além de potencialmente conter viés, em especial em relação ao país onde se deu o avistamento. Relatos falsos também são esperados, dada a relativa proteção que uma descrição via rede fornece a quem a faz.

Além de descrever como a base foi coletada, também faz parte de sua caracterização:

- Fornecer o tamanho total da base (número de observações), da subamostra escolhida para análise inicial, bem como do método de coleta dessa subamostra a partir da base.
- A caracterização das **variáveis** contidas na base (sua descrição, nível etc.)
- A definição dos **fatores** que você pretende observar (a partir de sua questão de pesquisa), e de como esses serão obtidos a partir das variáveis constantes da base (ou seja, explique como as variáveis escolhidas contribuem para os fatores definidos). Note que os fatores são os que fornecerão a resposta à(s) sua(s) questão(ões) de pesquisa, enquanto que as variáveis são as medições que comporão esses fatores e que, direta ou indiretamente, fornecerão valores a eles.
- Uma análise crítica das limitações da relação entre variáveis e respectivos fatores definida em seu estudo.
- Uma **justificativa** para cada escolha feita, seja da base, dos fatores (de como estes contribuirão para a resposta da questão de pesquisa), ou das variáveis que comporão os fatores (de como essas se relacionam a eles).

Observações:

- Note que o conjunto de dados do exemplo foi baixado, sendo verificado tão somente seu tamanho. Até agora, nada mais foi visto, evitando assim qualquer viés além, naturalmente, do gerado pelo conhecimento do número de observações totais, que poderia limitar a escolha do algoritmo de aprendizado de máquina a ser implementado.
- É essencial que seja tomada uma subamostra da base, e que esta seja caracterizada. Caso não seja possível tomá-la, deve-se justificar e incluir esse fato como uma limitação.
- Na ausência de qualquer informação, podemos apelar para a amostragem aleatória simples para obtenção da subamostra. Essa decisão, no entanto, e a depender do conjunto de dados, pode ter de ser revista quando separarmos o conjunto em treino e teste, por exemplo.

2.3 Passo 3: Explore os dados, visualize

A exploração dos dados será feita em trabalho futuro. Aqui, cabe a você apenas esboçar como irá explorar os dados. Em especial:

- Defina onde se dará a exploração (a menos de impossibilidade, deve ser na subamostra). Você deve definir também o que fará com a subamostra após a exploração. Como a subamostra é coletada e o que será dela após a exploração é uma decisão metodológica. Naturalmente, esse conjunto está “sujo”, por ter sido olhado para que decisões pudessem ser tomadas. No entanto, e como nenhum dado foi realmente visto ou analisado, não se espera que seja uma poluição grande. O importante é justificar e **não usar esse conjunto para as conclusões finais**.
- Não esqueça de incluir passos como uma potencial curadoria dos dados.
- Identifique como pretende observar, que gráficos pretende usar etc. **Justifique suas escolhas**. Naturalmente, coisas podem mudar, mas aqui já há espaço para identificar quando um tipo de gráfico está sendo proposto para o nível errado de dado.

2.4 Modele os dados

Também a modelagem será feita em trabalho futuro. Aqui você deve apresentar suas ideias sobre:

- Que modelos de aprendizado de máquina aplicar, relacionando-os aos tipos e níveis das variáveis da base, bem como à questão de pesquisa.
- Potenciais transformações nos dados, necessárias para aplicação dos modelos de aprendizado.

2.5 Avalie os modelos

Aqui você deve dizer como pretende avaliar os modelos propostos. Mais especificamente,

- Quais dados serão apresentados aos modelos?
- Como o conjunto de dados será dividido? (Por enquanto, só lembre de reservar uma porção **intocada** para teste final)
- Que medidas de desempenho pretende usar? Onde serão aplicadas?

2.6 Comunique os resultados

Aqui cabe definir

- Qual seu público alvo?
- Dado seu público alvo, qual informação será apresentada e em que profundidade?

2.7 Passo 4: Refine a(s) questão(ões) de pesquisa(s)

Naturalmente, por este ser um planejamento não teremos as questões propriamente ditas. Contudo, podemos prever sua existência futura.

Exemplo:

A partir de uma análise gráfica e estatística da amostra de dados serão levantadas questões mais específicas, a serem verificadas no conjunto de dados não vistos. Nesse sentido, algumas **possíveis** questões, passíveis de serem exploradas, são:

- Há alguma variação ou padrão entre a forma do objeto avistado e o país, ou cidade, do avistamento?
- Existe tal variação ou padrão em relação ao horário de avistamento (separado em diurno e noturno, por exemplo), mês ou ano e a localização geográfica?
- Quais países e cidades apresentam mais relatos de avistamentos?
- O número de avistamentos dependeu da latitude ou da longitude?
- Seria possível prever automaticamente, dado um subconjunto das variáveis apresentadas, algum dos padrões detectados?

A adequabilidade das questões supracitadas necessita, naturalmente, de comprovação a partir da análise exploratória. Essas questões, bem como as novas questões levantadas a partir da análise da amostra, deverão ser posteriormente verificadas por meio de análises estatísticas ou aplicação de métodos de aprendizado de máquina. A definição de qual método usar dependerá da quantidade de dados disponíveis, bem como da questão a ser respondida, a partir da qual será definida a abordagem a ser utilizada, se supervisionada de regressão ou de classificação, ou se não supervisionada.

3 Material para Entrega

A entrega será feita única e exclusivamente via eDisciplinas. Você deve criar um arquivo “No_USP.pdf” (em que No_USP é seu número USP) contendo a descrição do planejamento do experimento.

Deve ser submetido um único arquivo por grupo (ou seja, um único integrante irá fazer a submissão), sendo que o documento do planejamento deverá conter o nome e número usp de **todos** os participantes.

4 Data de Entrega

A data final de entrega é 05/04/2026.

5 Critérios de Avaliação

Para a avaliação, serão observados os seguintes critérios:

- As caracterizações e descrições apresentadas, bem como as justificativas para as escolhas feitas;
- A exequibilidade geral do estudo, ou seja, o quanto o planejamento permite a execução do estudo;
- A exequibilidade do estudo no tempo, ou seja, se sua execução é factível no tempo que será dado para tal.

6 Por fim...

O exemplo mostrado nesse documento, como mencionado, deve ser tomado apenas como um guia. Note que ele descreve um procedimento passível de reprodução, cujo objetivo é identificar questões de pesquisa, descrevendo como essas poderão ser respondidas, mas sem esquecer de dar um alto grau de liberdade ao pesquisador. De fato, as únicas “amarras” feitas se referem ao tema geral, conforme definido pela questão inicial, e à base de dados analisada.

O cronograma para isso tudo vai depender de vocês.